


Laws of Text: 词频长尾、词表增长与文本聚集性


图文讲义版：用原 PPT 作为视觉锚点，按“概念故事线 + 直觉解释 + 考试速记”整理。

Word 是 IR 的基本表示单位 → 词频分布极不均匀：少数高频词 + 大量低频词 → Zipf's law: rank 与 frequency/probability 近似反比 → Benford's law: 自然数字首位也非均匀 → Heaps' law: collection 变大时 vocabulary 持续增长但变慢 → Clumping/contagion: 词是稀有但会局部聚集的事件 → 应用：估计 index size、query processing cost、preprocessing 效果

9/23/25



1



2

1

这节课一句话

这节课告诉你文本不是随机沙子，而是有稳定统计脾气：少数词极高频、大量词极低频、词表一直长、词一出现就容易在附近再出现。

1. 为什么 IR 要关心 text laws

9/23/25

You can try with me ...

- Shell commands: cat, sort, uniq, grep
- Python (or alternative)
- Excel (or alternative)
- Download the following:
 - Bible: <http://www.gutenberg.org/cache/epub/10/pg10.txt>

Walid Magdy, TTDS 2025/2026

THE UNIVERSITY of EDINBURGH

3

Words' nature

- Word → basic unit to represent text
- Certain characteristics are observed for the words we use!
- These characteristics are very consistent, that we can apply laws for them
- These laws apply for:
 - Different languages
 - Different domains of text

Walid Magdy, TTDS 2025/2026

THE UNIVERSITY of EDINBURGH

4

2

原 PPT 第 2 页

人话直觉

如果你要建搜索引擎，不能只问“文本里有什么词”，还要问“这些词通常怎样分布”。

精确定义 / 机制：IR 通常以 word/term 作为表示文本的基本单位。讲义强调词的某些 characteristics 在不同语言 and 不同领域中都很一致，因此可以用 laws 描述。了解这些规律能帮助估计 vocabulary size、index size、postings list 长度、query processing 代价，也能解释 stop words、rare terms 和 preprocessing 的系统影响。

考试问法：若问为什么学 text laws，答统计规律帮助理解和设计 indexing、compression、query processing、preprocessing 与大规模文本系统。

2. 词频长尾：文本世界不是平均分配

9/23/25

Frequency of words

- Some words are very frequent
e.g. "the", "of", "to"
- Many words are less frequent
e.g. "schizophrenia", "bazinga"
- ~50% terms appears once
- Frequency of words has hard exponential decay



Walid Magdy, TTDS 2025/2026

THE UNIVERSITY OF EDINBURGH


Zipf's Law:

- For a given collection of text, ranking unique terms according to their frequency, then:

$$r \times P_r \cong \text{const}$$

- r , rank of term according to frequency
- P_r , probability of appearance of term

- $P_r \cong \frac{\text{const}}{r} \rightarrow f(x) \cong \frac{1}{x}$



Walid Magdy, TTDS 2025/2026

THE UNIVERSITY OF EDINBURGH

3

原 PPT 第 3 页

人话直觉

英语里 the、of、to 像城市主干道，车流巨大；schizophrenia、bazinga 像偏僻小巷，偶尔才有人经过。

精确定义 / 机制：词频分布高度不均匀：少数词非常 frequent，大量词 less frequent，讲义指出约 50% terms appear once。频率随 rank 呈 hard exponential decay。这解释了为什么高频 stop words 对主题区分能力弱但处理代价高，而低频词往往更有判别力。

考试问法：可考“词频分布特点”或“为什么 stop words 高频但不区分主题”：回答少数高频词 + 大量 singleton/rare terms + 长尾。

3. Zipf's law: rank $\times$ probability 近似常数

9/23/25

Frequency of words

- Some words are very frequent
e.g. "the", "of", "to"
- Many words are less frequent
e.g. "schizophrenia", "bazinga"
- ~50% terms appears once
- Frequency of words has hard exponential decay



Wahid Magdy, TTDS 2025/2026

THE UNIVERSITY OF EDINBURGH


Zipf's Law:

- For a given collection of text, ranking unique terms according to their frequency, then:

$$r \times P_r \cong \text{const}$$

- r , rank of term according to frequency
- P_r , probability of appearance of term

- $P_r \cong \frac{\text{const}}{r} \rightarrow f(x) \cong \frac{1}{x}$



Wahid Magdy, TTDS 2025/2026

THE UNIVERSITY OF EDINBURGH

3

原 PPT 第 3 页

人话直觉

把词按频率排队，第一名大概比第二名多，第二名比第三名多；名次越靠后，频率按反比例掉下去。

精确定义 / 机制: Zipf's law 描述: 在给定文本集合中, unique terms 按 frequency 排序后, term 的 rank r 与其出现概率 P_t 的乘积近似为常数。若用 frequency 而不是 probability, 也常写成 $r \times \text{freq}_t$ 近似常数。它是理解 inverted index 稀疏性和 postings list 长短差异的核心规律。

$$r \times P_t \approx \text{constant} \quad \text{or} \quad r \times \text{freq}_t \approx \text{constant}$$

考试问法: 若考 Zipf, 必须写公式、解释 r 和 P_t/freq_t , 并说明意义: 少数高频词、长尾低频词、index postings 极不均匀。

4. Zipf 对索引和查询处理的影响

9/23/25

Zipf's Law:

Wikipedia abstracts
→ 3.5M En abstracts

$r \times P_r \cong const \rightarrow$
 $r \times freq_r \cong const$

Term	Rank	Frequency	$r \times freq$
the	1	5,134,790	5,134,790
of	2	3,102,474	6,204,948
in	3	2,607,875	7,823,625
a	4	2,492,328	9,969,312
is	5	2,181,502	10,907,510
and	6	1,962,326	11,773,956
was	7	1,159,088	8,113,616
to	8	1,088,396	8,707,168
by	9	766,656	6,899,904
an	10	566,970	5,669,700
it	11	557,492	6,132,412
for	13	493,374	5,970,456
as	14	480,277	6,413,862
on	15	471,544	6,723,878
from	16	412,785	7,073,160

Walid Magdy, TTDS 2025/2026

THE UNIVERSITY of EDINBURGH

7

Practical

Collection	# words	File size
Bible	824,054	4.24 MB
Wiki abstracts	80,460,749	472 MB

Walid Magdy, TTDS 2025/2026

THE UNIVERSITY of EDINBURGH

8

4

原 PPT 第 4 页

人话直觉


查 the 像翻全城电话簿，查 bazinga 可能只看几条记录；同样是一个词，系统成本完全不同。

精确定义 / 机制：Wikipedia abstracts 示例显示 rank × frequency 在同一量级波动，说明真实 collection 里高频词 postings list 很长，低频词 postings list 很短。对于 inverted index，这意味着 dictionary 中大量 term 很稀疏，而少数 term 占据大量 occurrences。查询处理时通常优先利用更短、更有判别力的 postings list。

考试问法：系统题可问 Zipf 如何影响 index/query：高频词存储与处理成本高，低频词更 discriminative，排序和优化需利用 term statistics。

5. Benford's law: 首位数字也有偏见

9/23/25



Benford's Law:

- First digit of a number follows a Zipf's like law!
 - Terms frequencies
 - Physical constants
 - Energy bills
 - Population numbers
- Benford's law:
$$P(d) = \log\left(1 + \frac{1}{d}\right)$$

Walid Magdy, TTDS 2025/2026

THE UNIVERSITY of EDINBURGH

5

原 PPT 第 5 页

人话直觉

如果数字真平均，1 到 9 当首位应差不多；但很多自然数据里，1 开头远比 9 开头常见。



精确定义 / 机制： Benford's law 说明许多自然数据的 first digit distribution 不是 uniform，而是小数字更常出现。讲义列出 term frequencies、physical constants、energy bills、population numbers 等例子。它与 Zipf 有相似精神：自然数据常呈非均匀、长尾、跨数量级分布。

$$P(d) = \log\left(1 + \frac{1}{d}\right)$$

考试问法：若考 Benford，写 $P(d)=\log(1+1/d)$ ，解释 d 是首位数字，并说明它可出现在 term frequencies 等自然统计中。

6. Heaps' law: 词表会长，但越长越慢

9/23/25



6

原 PPT 第 6 页

人话直觉

刚开始读一本书，几乎每行都有新词；读到后面，大多数词见过了，但人名、地名、专业词、拼写噪声还会不断冒出来。



精确定义 / 机制： Heaps' law 描述随着读入 words 数 n 增加，observed vocabulary size $v(n)$ 持续增长但速度下降。公式为 $v(n) = k n^b$ ，其中 $b < 1$ ，通常 $0.4 < b < 0.7$ 。 k 和 b 取决于 collection、language、domain 与 preprocessing。它可用于估计 dictionary size 和 index memory。

$$v(n) = k n^b, \quad 0.4 < b < 0.7, \quad b < 1$$

考试问法：若考 Heaps, 写公式, 解释 n 、 v 、 k 、 b , 强调 $b < 1$ 表示 sublinear growth; 用途是估计 vocabulary/index size。

7. 为什么 vocabulary 不会很快饱和

9/23/25



6

原 PPT 第 6 页

人话直觉

语言像活水：新闻人物、新产品、拼写错误、URL、代码、外语词会一直往词表里倒。

精确定义 / 机制：讲义指出即使 n 达到 80+ million, vocabulary 仍在增长。原因是大集合不断引入新实体、罕见专业词、拼写变体、数字代码和噪声。Heaps' law 对多数 collection 准确, 但 k, b 不同; 当 n 很小时不太准确。preprocessing 越激进, 例如 stemming、case folding、stop removal, 观察到的 vocabulary growth 可能越小。

考试问法：可考“为什么 Heaps 不 saturate”：答大型真实文本源不断产生新词、实体、噪声与变体; 小集合上 law 不稳定。

8. Clumping/contagion: 词是稀有但传染的事件

9/23/25

Clumping/Contagion in text

- From Zipf's law, we notice:
 - Most words do not appear that much!
 - Once you see a word once → expect to see again!
- Words are like:
 - Rare contagious disease
 - Not, rare independent lightning
- Words are rare events, but they are contagious


Walid Magdy, TTDS 2025/2026

THE UNIVERSITY of EDINBURGH

13

Clumping/Contagion in text

- Wiki abstract collection
 - Identify terms appeared only twice
 - Measure distance between the two occurrences of the terms:
 $d = n_{occurrence2} - n_{occurrence1}$
 - Plot density function of d
- Majority of terms appearing only twice appear close to each other.



Walid Magdy, TTDS 2025/2026

THE UNIVERSITY of EDINBURGH

14

7

原 PPT 第 7 页

人话直觉

lightning 是独立闪一下就没了；疾病会传染。词更像疾病：一篇文章开始聊 mitochondria，附近很可能又出现 mitochondria。

精确定义 / 机制：从 Zipf 可知多数词出现很少，但 once you see a word once, expect to see again。Clumping/contagion 指词项出现具有局部聚集性：词是 rare events, but contagious。原因是文本有 topic locality；同一主题在段落、文档或 passage 内连续展开。

考试问法：若考 contagion，关键词是 local burstiness/topic locality；说明它启发 proximity search、passage retrieval、positional index 和 compression。

9. Occurrence distance: 怎样观察 clumping

9/23/25

Clumping/Contagion in text

- From Zipf's law, we notice:
 - Most words do not appear that much!
 - Once you see a word once → expect to see again!
- Words are like:
 - Rare contagious disease
 - Not, rare independent lightning
- Words are rare events, but they are contagious


Walid Magdy, TTDS 2025/2026

THE UNIVERSITY of EDINBURGH

13

Clumping/Contagion in text

- Wiki abstract collection
 - Identify terms appeared only twice
 - Measure distance between the two occurrences of the terms:
 $d = n_{occurrence2} - n_{occurrence1}$
 - Plot density function of d
- Majority of terms appearing only twice appear close to each other.



Walid Magdy, TTDS 2025/2026

THE UNIVERSITY of EDINBURGH

14

7

原 PPT 第 7 页

人话直觉

如果一个只出现两次的词，两次位置总是离得很近，就说明它不是均匀撒在整本书里的。

精确定义 / 机制：讲义用 Wiki abstract collection 做实验：找只出现两次的 terms，测两次 occurrences 的距离 d ，并画 d 的 density function。结果显示多数只出现两次的词出现距离较近。这为“文本按主题局部组织”提供了统计证据。

$$d = n_{occurrence\ 2} - n_{occurrence\ 1}$$

考试问法：若问如何验证 clumping，回答：选择 frequency=2 的 terms，计算两次 occurrence position 的距离，观察距离分布是否集中在小 d 。

10. Text laws 的 practical 用法

9/23/25

Applying the laws

- Given a collection of 20 billion terms,
- What is the number of unique terms?

Heap's law: $v(n) = k \times n^b$, assume $k = 0.25$, $b = 0.7$

- What is the number of terms appearing once?

Walid Magdy, TTDS 2025/2026

THE UNIVERSITY
of EDINBURGH

15

Summary

- Text follows well-known phenomena
- Text Laws:
 - Zipf
 - Heap
 - Contagion in text
- Shell commands:
 - cat, zcat, gzcat, more, tr, sort, uniq, ">", "|", "[]"
- Try it on another language ...

Walid Magdy, TTDS 2025/2026

THE UNIVERSITY
of EDINBURGH

16

8

原 PPT 第 8 页

人话直觉

这些 law 不是数学装饰，而是工程估算器：还没建索引，就能预判词表和处理成本。

精确定义 / 机制：讲义用 Heaps' law 估算 20 billion terms、 $k=0.25$ 、 $b=0.7$ 时 unique terms 约 4M。实践中可用 cat、zcat/gzcat、more、tr、sort、uniq、redirection 和 pipe 统计词频、观察 Zipf、统计 singleton terms 与 vocabulary growth。不同语言/领域也应重新实验，因为参数会变化。

$$v(20B) = 0.25 \times (20B)^{0.7} \approx 4M$$

考试问法：应用题可能给 n 、 k 、 b 让你估 $v(n)$ ，或问如何用 shell 观察词频分布；回答时连接 law 与 index size/query cost。

考试速记版

- Text laws 描述词频、词表增长和词项位置的稳定统计规律。

- 约 50% terms 可能只出现一次，词频呈长尾。
- Zipf: $r \times P_t \approx \text{constant}$, rank 越低频率越高。
- Benford: $P(d) = \log(1 + 1/d)$, 自然数字首位非均匀。
- Heaps: $v(n) = k n^b$, $b < 1$, vocabulary sublinear growth。
- Vocabulary 不会快速饱和，因为新实体、拼写、噪声、专业词不断出现。
- Clumping: 词是 rare but contagious, 出现后附近更可能再出现。
- 应用: 估 index size、postings length、query cost、preprocessing effect。

一段稳妥考场回答

Text laws describe stable statistical patterns in large text collections. Zipf's law says that when terms are ranked by frequency, rank times term probability or frequency is approximately constant, producing a few very frequent words and a long tail of rare terms. Heaps' law says vocabulary grows as $v(n) = k n^b$ with $b < 1$, so new terms keep appearing but at a decreasing rate, which helps estimate dictionary and index size. Clumping or contagion says words are rare but locally bursty: once a term appears, it is more likely to appear again nearby because text has topic locality.