


IR Evaluation: 从“看起来不错”到可复现实验指标


图文讲义版：用原 PPT 作为视觉锚点，按“概念故事线 + 直觉解释 + 考试速记”整理。

为什么要评估：Lab 输出本身不能说明好坏 → 两类评估：system-centered 与 user-centered → 三维目标：effectiveness、efficiency、usability → Cranfield paradigm：固定文档、查询、相关性判断 → set-based measures：precision、recall、F-measure → rank-based measures：P@k、R-precision、AP/MAP → graded relevance：DCG 与 nDCG → 考试核心：按任务选择指标并解释假设

10/14/25



1



2

1

这节课一句话

这节课一句话：IR evaluation 把检索系统从主观感觉拉回实验科学，用固定 collection、query/topic、relevance judgments 和合适指标来回答“这个 ranking 是否真的更好”。

1. 1. 为什么 IR 必须被实验化评估

10/14/25

Lab 3 output		Is that a good performance?
1, 65, 4.8040	2, 3549, 7.0396	3, 3354, 4.6113
1, 3533, 4.7264	2, 305, 6.8394	3, 3345, 4.5087
1, 3562, 3.5454	2, 288, 6.6742	3, 268, 3.6606
1, 3608, 3.4910	2, 223, 6.1252	3, 328, 3.4825
1, 141, 3.3262	2, 219, 4.8626	3, 21, 3.3984
1, 361, 3.3262	2, 3762, 4.8626	3, 304, 3.3722
1, 92, 3.2311	2, 3663, 4.5415	3, 313, 3.3436
1, 3829, 3.1818	2, 3766, 3.9924	3, 3790, 3.1796
1, 3420, 3.1273	2, 188, 3.8844	3, 55, 3.0462
1, 3734, 3.0561	2, 3360, 3.0988	3, 217, 2.8492
1, 3387, 2.9626	2, 3408, 3.0315	3, 361, 2.8348
1, 3599, 2.9626	2, 3390, 2.8498	3, 3789, 2.7158

Walid Magdy, TTDS 2025/2026

THE UNIVERSITY of EDINBURGH

5

Configure your system
• About the system: • Stopping? Tokenise? Stemming? n-gram char? • Use synonyms improve retrieval performance? • Corresponding experiment? • Run your search for a set of queries with each setup and find which one will achieve the best performance • About the user: • Is letting users weight search terms a good idea? • Corresponding experiment? • Build two different interfaces, one with term weighting functionality, and one without; run a user study

Walid Magdy, TTDS 2025/2026

THE UNIVERSITY of EDINBURGH

6

3

原 PPT 第 3 页

人话直觉


一串 docID 和 score 就像餐厅菜单上的价格：它告诉你系统“给了什么”，但没告诉你“好不好吃”。IR evaluation 要补上这把尺子。

精确定义 / 机制：检索系统的输出只有在和用户 information need、相关性判断、baseline 或其他系统比较后才有意义。第 3 页用 Lab 3 output 追问“Is that a good performance?”，说明裸 ranking score 不是评价；第 4 页把 evaluation 分成 system-centered laboratory experiment 和 user-centered studies。考试通常希望你说出：IR 是 experimental science，因为它提出假设、控制变量、用可复现指标比较系统，并据此改进方法。


考试问法：若问“Why is IR an experimental science?”，答 hypothesis + baseline + fixed test collection + measurable effectiveness + reproducible comparison。

2. 2. Evaluation 的三维度：不只看相关性

10/14/25



9



10

5

原 PPT 第 5 页

人话直觉

一个搜索引擎像餐厅：菜要好吃（effectiveness），上菜要快（efficiency），菜单还要好用（usability）。只拿一个维度吹系统好，答案就会偏。

精确定义 / 机制：Effectiveness 关心返回文档是否满足信息需求；efficiency 关心 retrieval time、indexing time、index size；usability 关心用户学习成本、灵活性和 novice/expert users 的体验。本讲后续主要聚焦 effectiveness，但第 5 页提醒考试中不要把 evaluation 简化成 MAP 一个数字。

考试问法：若问“三维度是什么”，逐一定义并给例子；若问本讲指标衡量什么，强调主要是 effectiveness。

3. 3. Cranfield Paradigm: 把检索评估做成可复现实验

10/14/25

Reusable IR Test Collection

- **Collection of Documents**
 - Should be "representative" to a given IR task
 - Things to consider: size, sources, genre, topics, ...
- **Sample of information need**
 - Should be "randomized" and "representative"
 - Usually formalized **topic** statements (query + description)
- **Known relevance judgments**
 - Assessed by humans, for each topic-document pair
 - Binary/Graded
- **Evaluation measure**

Wahid Magdy, TTDS 2025/2026

11

Good Effectiveness Measures

- Should capture some aspect of what the user wants
 - IR → Do the results satisfy user's information need?
- Should be easily replicated by other researchers
- Should be easily comparable
 - Optimally, expressed as a single number
 - Curves and multiple numbers are still accepted, but single numbers are much easier for comparison
- Should have predictive value for other situations
 - What happens with different queries on a different document collection?

Wahid Magdy, TTDS 2025/2026

12

6

原 PPT 第 6 页

人话直觉


Cranfield 就像给所有选手同一张试卷、同一份参考答案、同一套评分标准；这样比较系统才公平。

精确定义 / 机制：Reusable IR test collection 包括 representative document collection、representative information needs/topics、human relevance judgments 和 evaluation measure。系统在固定 collection 和 topics 上输出结果，evaluation module 用 judgments 计算 effectiveness。它牺牲一部分真实交互复杂性，换来自动化、可重复、可比较的实验评估。


考试问法：若问“test collection contains what?”，按 documents、topics、judgments、measure 四件套回答，并说明 relevance 可 binary 或 graded。

4. 4. Precision 与 Recall: 干净 vs 找全

10/14/25



15



16

8

原 PPT 第 8 页

人话直觉

Precision 像你捞上来的一网鱼里有多少真鱼；recall 像海里所有真鱼你捞上来多少。前者怕垃圾，后者怕漏掉。

精确定义 / 机制： Precision 是 retrieved documents 中 relevant 的比例；recall 是所有 relevant documents 中被 retrieved 的比例。第 8 页用 relevant/retrieved 的交集和 TP/FP/FN 展示公式。第 10 页的 trade-off 图说明二者常互相拉扯：严格检索可能 precision 高但 recall 低，宽松检索可能 recall 高但 precision 低。

$$P = \frac{|rel \cap ret|}{|ret|} = \frac{TP}{TP + FP}; \quad R = \frac{|rel \cap ret|}{|rel|} = \frac{TP}{TP + FN}$$

考试问法：若给 TP/FP/FN 计算，先画 retrieved 与 relevant 的集合；若问 trade-off，说明阈值、query broadening 或 ranking cutoff 会改变 P/R。

5. 5. 为什么 Accuracy 不适合 IR, F-measure 怎样补位

10/14/25

One Measure? F-measure

$$F_1 = \frac{2 \cdot P \cdot R}{P + R}$$
$$F_\beta = \frac{(\beta^2 + 1)P \cdot R}{\beta^2 P + R}$$

- Harmonic mean of recall and precision
 - Emphasizes the importance of small values, whereas the arithmetic mean is affected more by outliers that are unusually large
- Beta (β) controls relative importance of P and R
 - $\beta = 1$, precision and recall equally important $\rightarrow F_1$
 - $\beta = 5$, recall five times more important than precision

Walid Magdy, TTDS 2025/2026

THE UNIVERSITY of EDINBURGH

21

F-measure?

- For query Q, collection has 8 relevant documents:

System	Precision	Recall	F1	F5	F0.5	F0
A	0.500	0.625	0.556	0.619	0.521	0.500
B	0.500	0.750	0.600	0.736	0.536	0.500
C	0.417	0.625	0.500	0.613	0.446	0.417
D	0.333	0.500	0.400	0.491	0.357	0.333
E	0.375	0.375	0.375	0.375	0.375	0.375
F	0.500	0.750	0.600	0.736	0.536	0.500
G	0.800	0.500	0.615	0.507	0.714	0.800

P=6/8
R=5/8

P=6/12
R=6/8

P=5/12
R=5/8

P=4/12
R=4/8

P=6/12
R=6/8

Walid Magdy, TTDS 2025/2026

THE UNIVERSITY of EDINBURGH

22

11

原 PPT 第 11 页

人话直觉

在海量文档里, 大多数文档本来就不相关; 一个系统什么都不返回, 也可能靠 TN 拿到漂亮 accuracy, 但用户会空手而归。

精确定义 / 机制: IR collection 中 irrelevant documents 通常远多于 relevant documents, 因此 TN 会支配 accuracy, 使它掩盖检索质量。F-measure 用 harmonic mean 合并 precision 与 recall, 短板很低时整体分数也低; F_β 用 β 控制 recall 相对 precision 的重要性, $\beta=1$ 等权, $\beta>1$ 更看重 recall。

$$F_1 = \frac{2PR}{P+R}; \quad F_\beta = \frac{(\beta^2 + 1)PR}{\beta^2 P + R}$$

考试问法: 若问 accuracy 为什么不好, 答 class imbalance + TN 巨大 + 不反映用户看到的结果; 若问 F_β , 解释 harmonic mean 和 β 的偏好。

6. 6. Ranked Retrieval: 排名位置本身就是质量

10/14/25

Rank-based IR measures

- Consider systems A & B
 - Both retrieved 10 docs, only 5 are relevant
 - P, R & F are the same for both systems
 - Should their performances considered equal?
- Ranked IR requires taking "ranks" into consideration!
- How to do that?

Wahid Magdy, TTDS 2025/2026

THE UNIVERSITY of EDINBURGH

23

Which is the best ranked list?

- For query Q, collection has 8 relevant documents:

Wahid Magdy, TTDS 2025/2026

THE UNIVERSITY of EDINBURGH

24

12

原 PPT 第 12 页

人话直觉

两个系统都找到了 5 篇相关文档，但一个把它们放在前五，另一个散落到第十页；用户体验完全不同。

精确定义 / 机制： Set-based P/R/F 不关心 relevant documents 出现在第几名。第 12 页用 A/B 两个 ranked list 说明：相同 P、R、F 也可能有不同用户满意度。Rank-based measures 因此把 rank 纳入指标，特别适合用户通常从上往下浏览、很少看完整列表的搜索场景。

考试问法： 若问为什么 ranked IR 不能只用 P/R/F，答它们忽略 ordering；应使用 P@k、R-precision、AP/ MAP、nDCG 等。

7. 7. P@K 与 R-Precision: 给排名切一刀

10/14/25

R-Precision

- For a query with known r relevant documents
→ R-precision is the precision at rank r ($P@r$)
- r is different from one query to another
- Concept:
It examines the ideal case: getting all relevant documents in the top ranks
- Is it realistic?

Walid Magdy, TTDS 2025/2026

THE UNIVERSITY of EDINBURGH

27

R-Precision

- For query Q , collection has 8 relevant documents:

	A	B	C	D	E	F	G
1	R		R	R	R		R
2			R	R			R
3	R			R	R	R	
4							R
5	R		R	R		R	
6		R					
7	R	R			R	R	
8		R					
9	R						
10		R					
11							
12							

Walid Magdy, TTDS 2025/2026

THE UNIVERSITY of EDINBURGH

28

14

原 PPT 第 14 页

人话直觉

P@K 像只检查搜索结果第一页；R-precision 像问：如果这个 query 一共有 r 篇相关文档，前 r 名里你放进来多少？

精确定义 / 机制：P@K 在固定 cutoff k 处计算 precision，适合 web search 中用户只看 top k 的假设，但不同 query 的相关文档总数不同，所以平均时可能粗糙。R-precision 令 cutoff 等于该 query 的 relevant document 数 r ，即 $P@r$ ，试图检查理想情况下所有相关文档是否挤进最前面的 r 个位置。

$$P@k = \frac{\#\{\text{relevant documents in top } k\}}{k}; \quad R\text{-precision} = P@r$$

考试问法：若问 P@K 局限，说它忽略 k 之后的 relevant docs，且不同 query 上可比性有限；若问 R-precision，强调 r 随 query 改变。

8. 8. AP/MAP: 把每个 relevant 出现时的惊喜累计起来

10/14/25

AP & MAP

$$AP = \frac{1}{r} \sum_{k=1}^n P(k) \times rel(k)$$

where, r : number of relevant docs for a given query
 n : number of documents retrieved
 $P(k)$ precision @ k
 $rel(k)$: 1 if retrieved doc @ k is relevant, 0 otherwise.

$$MAP = \frac{1}{Q} \sum_{q=1}^Q AP(q)$$

where, Q : number of queries in the test collection

Walid Magdy, TTDS 2025/2026

THE UNIVERSITY of EDINBURGH

35

AP/MAP

$$AP = \frac{1}{r} \sum_{k=1}^n P(k) \times rel(k)$$

- A mix between precision and recall
- Highly focus on finding relevant document as early as possible
- When $r=1 \rightarrow MAP = MRR$ (mean reciprocal rank $\frac{1}{k}$)
- MAP is the most commonly used evaluation metric for most IR search tasks
- Uses binary relevance: $rel = 0/1$

Walid Magdy, TTDS 2025/2026

THE UNIVERSITY of EDINBURGH

36

18

原 PPT 第 18 页

人话直觉

AP 像用户一路往下看，每遇到一篇相关文档就记录一次“到目前为止列表有多干净”，最后对这些关键时刻求平均。

精确定义 / 机制： Average Precision 对一个 query，把每个 rank k 的 precision 乘以 $rel(k)$ ，只在该位置文档 relevant 时贡献分数，再除以该 query 的 relevant 文档总数 r 。MAP 是 across queries 的 AP 平均。它同时奖励 relevant documents 排得靠前和尽量找全，是 binary relevance ranked retrieval 的经典指标。

$$AP = \frac{1}{r} \sum_{k=1}^n P(k) rel(k); \quad MAP = \frac{1}{|Q|} \sum_{q \in Q} AP(q)$$

考试问法：若考计算 AP，逐行写 $P(k)$ ，只在 $rel(k)=1$ 的位置相加；若问 MAP，说明它是 query-level AP 的 mean，不是把所有文档混在一起算。

9.9. DCG/nDCG: 相关性有等级，排名有折扣

10/14/25

nDCG

k	G	DG	DCG@k	iG	IDG	IDCG@k	nDCG@k
1	3	3	3	3	3.00	3	1.00
2	2	2	5	3	3.00	6	0.83
3	3	1.89	6.89	3	1.89	7.89	0.87
4	0	0	6.89	2	1.00	8.89	0.78
5	0	0	6.89	2	0.86	9.75	0.71
6	1	0.39	7.28	2	0.77	10.52	0.69
7	2	0.71	7.99	1	0.36	10.88	0.73
8	2	0.67	8.66	0	0.00	10.88	0.80
9	3	0.95	9.61	0	0.00	10.88	0.88
10	0	0	9.61	0	0.00	10.88	0.88

Walid Magdy, TTDS 2025/2026

THE UNIVERSITY OF EDINBURGH

43

Summary:

- IR test collection:
 - Document collection
 - Query set
 - Relevant judgements
 - IR measures
- IR measures:
 - R, P, F → not commonly used
 - P@k, R-precision → used sometimes
 - MAP → the most used IR measure
 - nDCG → the most used measure for web search

Walid Magdy, TTDS 2025/2026

THE UNIVERSITY OF EDINBURGH

44

22

原 PPT 第 22 页

人话直觉

网页结果不是只有“有用/没用”：完美答案、部分答案、擦边答案价值不同；而且同样的答案放第 1 名比第 10 名更值钱。

精确定义 / 机制： DCG 使用 graded relevance 作为 gain，并随着 rank 下降用 log discount 降低贡献。nDCG 再用 ideal DCG 归一化，让不同 query、不同相关性分布的分数可比较，通常范围在 0 到 1。第 20–22 页强调两个假设：高度相关更有用；越靠后越不容易被用户检查。

$$DCG@k = \sum_{i=1}^k \frac{gain_i}{\log_2(i+1)}; \quad nDCG@k = \frac{DCG@k}{IDCG@k}$$

考试问法： 若问为什么 nDCG 常用于 web search，答 web results 常有 graded relevance，且用户强烈关注顶部排名；若考公式，先算 DCG，再除以 IDCG。

考试速记版

- Cranfield = documents + topics + relevance judgments + evaluation measure。
- Precision 问 retrieved 里多少 relevant; recall 问 relevant 里多少 retrieved。
- Accuracy 在 IR 中常被大量 true negatives 扭曲。
- F1 是 P/R harmonic mean; $F\beta$ 用 β 调 recall 与 precision 权重。
- P@K 适合 top-k 用户行为, 但忽略 k 后内容。
- AP 只在 relevant 出现的 rank 记录 precision; MAP 是 query AP 的平均。
- DCG/nDCG 处理 graded relevance 和 rank discount。
- 答题时永远先说任务假设, 再选指标。

一段稳妥考场回答

IR evaluation is usually framed as an experimental science: we fix a representative document collection, a representative set of information needs/topics, human relevance judgments, and an effectiveness measure, then compare systems or variants against a baseline. For unranked retrieval, precision and recall capture different errors: precision measures how many retrieved documents are relevant, while recall measures how many relevant documents are retrieved. Because ranked IR users care strongly about top positions, rank-aware measures such as P@k, R-precision, AP/ MAP and nDCG are needed. MAP averages each query's average precision over the test set and is suitable for binary relevance ranked retrieval; nDCG additionally handles graded relevance by discounting lower ranks and normalizing against the ideal ranking.