TTDS 08

Ranked Retrieval 2：概率模型、BM25 与语言模型

图文讲义版：用原 PPT 作为视觉锚点，按“概念故事线 + 直觉解释 + 考试速记”整理。

VSM heuristic → probabilistic uncertainty → PRP → relevance probability → BM25 → language model for IR → query likelihood → MLE zero problem → smoothing → model comparison

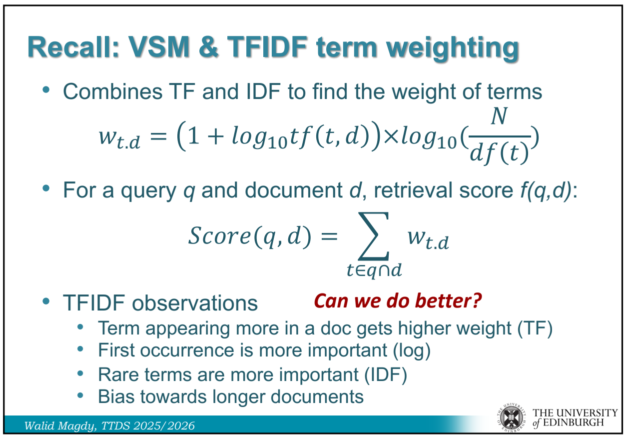

3

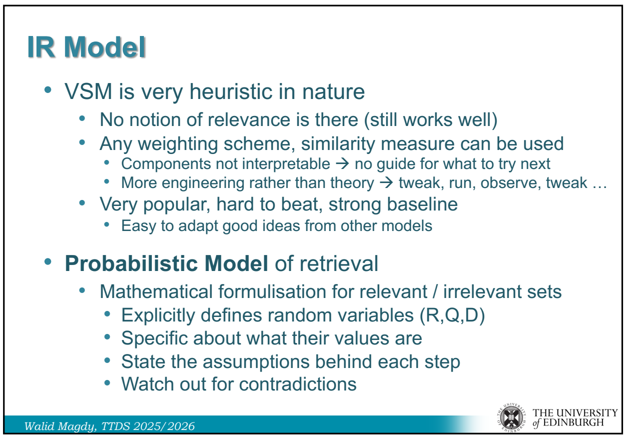

4

原 PPT 第 2 页

这节课一句话

这节课把 ranking 从 TF-IDF 的工程配方推进到概率视角：文档为什么相关、BM25 为什么稳、语言模型为什么能用“生成 query”的概率排序。

1. TF-IDF 很强，但理论感偏弱

10/7/25

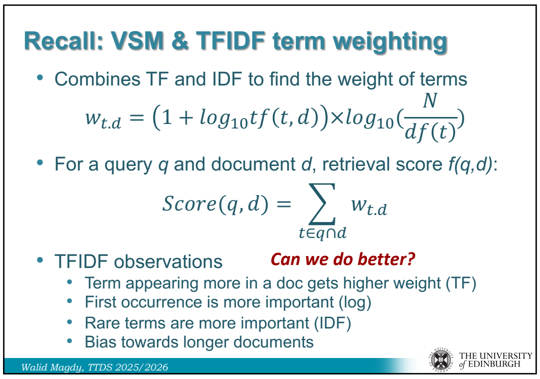

3

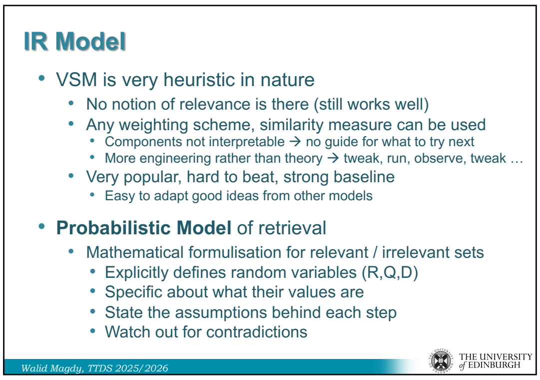

4

2

原 PPT 第 2 页

人话直觉

TF-IDF 像一套经验丰富的厨师配方：很好吃，但你还想知道每个调料为什么该这么放。

精确定义 / 机制： VSM/TF-IDF 没有显式建模 relevance，只是组合 weighting scheme 和 similarity measure。它非常流行、强 baseline、难以击败，但 components 不完全可解释，也容易依赖 tweak-run-observe 的工程循环。

考试问法： 若问为什么引入 probabilistic model，答 VSM heuristic、缺少 explicit relevance notion、概率模型能定义 random variables 和 assumptions。

2. PRP：按相关概率排序

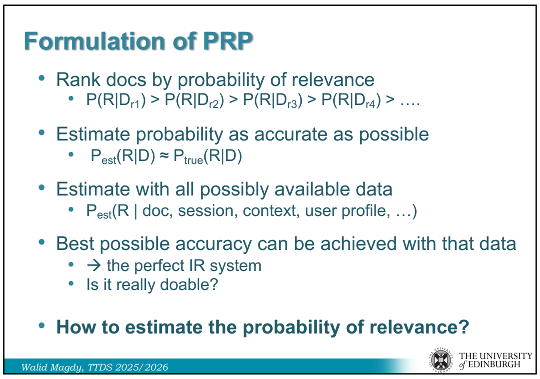

7

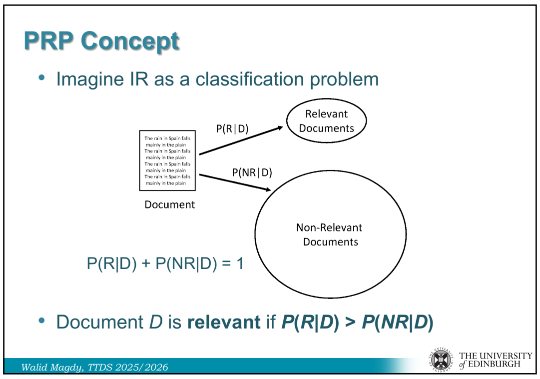

8

原 PPT 第 4 页

人话直觉

如果你能估计每篇文档“正中用户意图”的概率，那么最合理的事就是从最高概率开始排。

精确定义 / 机制： Probability Ranking Principle 认为，在可用数据下，如果系统能尽可能准确估计每个 document 对请求的 relevance probability，那么按该概率递减排序能获得最佳 effectiveness。

$$P(R = 1 \mid d_1, q) > P(R = 1 \mid d_2, q) \Rightarrow d_1 \succ d_2$$

考试问法： PRP 答题核心：rank by decreasing probability of relevance，probabilities estimated as accurately as possible from available data。

3. 相关概率不是读心术

Probability of Relevance

- What is P_{true}(rel | doc, query, session, user, …)?
  - Isn't relevance just the user's opinion?
    - User decides relevant or not, what is the "probability" thing?
- Search algorithm cannot look into your head (yet!)
  - Relevance depends on factors that algorithm cannot observe
    - SIGIR 2016 best paper award: *Understanding Information Need: an fMRI Study*
- Different users may disagree on relevance of the same doc
  - Even similar users, doing the same task, in the same context
- P_{true} (rel | Q, D):
  - Proportion of all unseen users / context / tasks for which D would have judged relevant to Q
- Similar to: P(die=6 | even and not square)

Walid Magdy, TTDS 2025/2026 THE UNIVERSITY of EDINBURGH

9

Okapi BM25 Model

- Based on the probabilistic model
  - A document D is relevant if **P(R=1|D) > P(R=0|D)**
- Extension to the "binary independence model"
  - **Binary features**: Document represented by a vector of binary features indicating term occurrence
  - Assume **term independence** (Naïve Bayes assumption) → BOW trick
- In 1995, *Stephan Robertson* with his group came up with the **BM25** Formula as part of the **Okapi** project.
- It outperformed all other systems in TREC
- Popular and effective ranking algorithm

Walid Magdy, TTDS 2025/2026 THE UNIVERSITY of EDINBURGH

10

原 PPT 第 5 页

人话直觉

系统看不到你脑子里的真实 need，只能根据 query、document、context、user profile 等影子去猜。

精确定义 / 机制：真实 relevance 受用户、任务、上下文影响，不同用户可能对同一 document 判断不同。P_true(rel|Q,D) 可理解为在未观察用户/情境/任务中，D 会被判 relevant 的比例；系统只能估计 P_est。

考试问法：若问 relevance probability 如何理解，不要说用户主观就没概率；要说是对不可见用户/场景的比例性估计。

4. BM25：概率模型落地成强公式

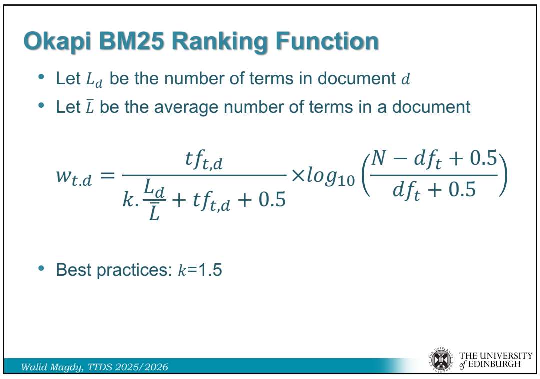

11

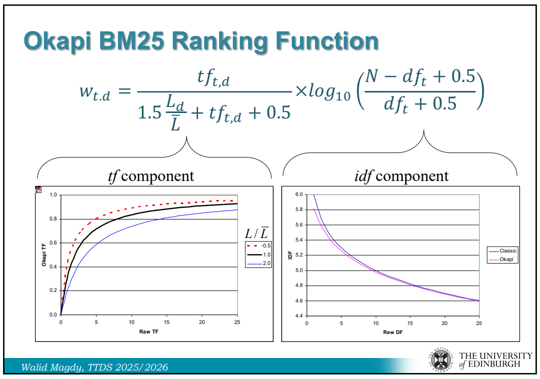

12

原 PPT 第 6 页

人话直觉

BM25 像 TF-IDF 的升级款避震车：仍奖励关键词出现和稀有性，但更稳地处理重复词和长文档。

精确定义 / 机制： BM25 源于 probabilistic retrieval/Binary Independence Model 的扩展，是经典且强大的 ranking function。它包含 term frequency saturation、IDF 和 document length normalization；k 控制 tf saturation，文档长度用 L_d/L_avg 调整。

$$w_{t,d} = \frac{tf_{t,d}}{tf_{t,d} + k\left((1-b) + b\frac{L_d}{L_{avg}}\right)} \log_{10} \frac{N - df_t + 0.5}{df_t + 0.5}$$

考试问法： 若考 BM25，答 saturated TF、IDF、length normalization，并说明 k 控制 tf 增长饱和。

5. BM25 为什么比朴素 TF-IDF 稳

Probabilistic Model in IR

- Focuses on the probability of relevance of docs
- Could be mathematically proved
- Different ways to apply it
- BM25 is the most common formula for it

- What other models could be still used in IR?

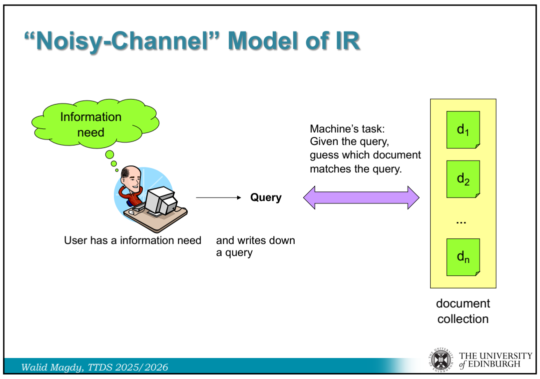

14

原 PPT 第 7 页

人话直觉

一个词出现 2 次比 1 次重要，但出现 200 次不该比 100 次再重要一倍；BM25 会让这种增长慢慢饱和。

精确定义 / 机制： BM25 与 TF-IDF 都奖励 document 内 query term 出现和 collection rare terms，但 BM25 更明确地处理 tf saturation 和 document length bias。长文档不会仅因词多而持续占优，重复词也不会无限加分。

考试问法： 比较 BM25 vs TF-IDF 时，重点说 BM25 显式加入 saturation 与 length normalization。

6. Language Model for IR：好文档会“说出”query

10/7/25

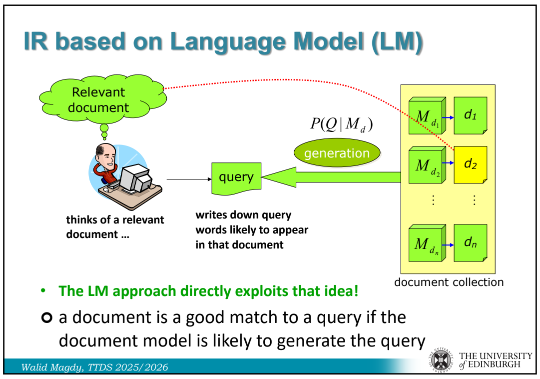

15

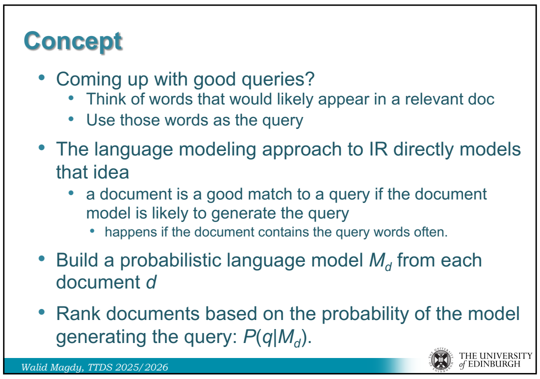

16

8

原 PPT 第 8 页

人话直觉

如果一篇文档的语言习惯很容易吐出你的 query，那么它很可能在讲你要找的东西。

精确定义 / 机制：LM approach 为每个 document 建 language model，并按 query likelihood P(q|M_d) 排序。Bayes rule 下 P(d|q) 与 P(q|d) 相关，若 P(q) 对所有 documents 相同、P(d) 作为相同 prior 或另行处理，就可以比较 P(q|M_d)。

$$P(d \mid q) = \frac{P(q \mid d)P(d)}{P(q)}$$

考试问法：若问 LM for IR 核心思想，答 document language model 生成 query 的概率越高，document 越相关。

7. Unigram LM 与 query likelihood

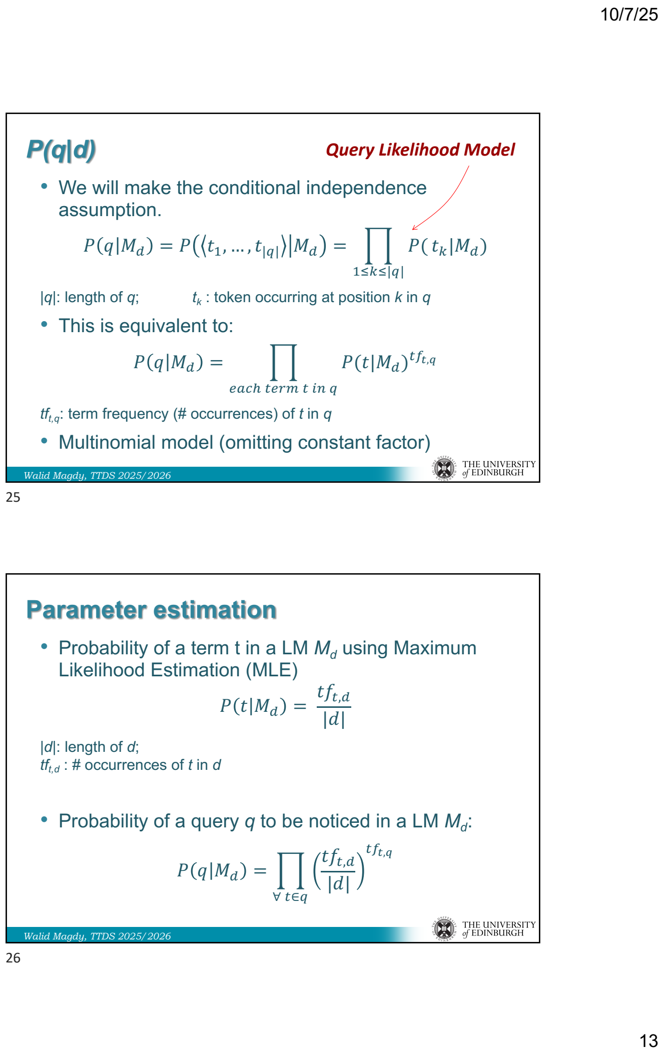

原 PPT 第 13 页

人话直觉

先假装 query 里的词像从一个词袋里独立抽球，这样复杂句子概率就能拆成单词概率乘积。

精确定义 / 机制：unigram LM 假设 terms 条件独立，不考虑顺序。query likelihood model 将 P(q|M_d) 分解为 query terms 在 document model 下概率的乘积，也可按 query term frequency 写成幂次形式。

$$P(q \mid M_d) = \prod_{t \in q} P(t \mid M_d)^{tf(t,q)}$$

考试问法：公式题要写 conditional independence assumption，并说明 M_d 是 document language model。

8. MLE 的零概率问题

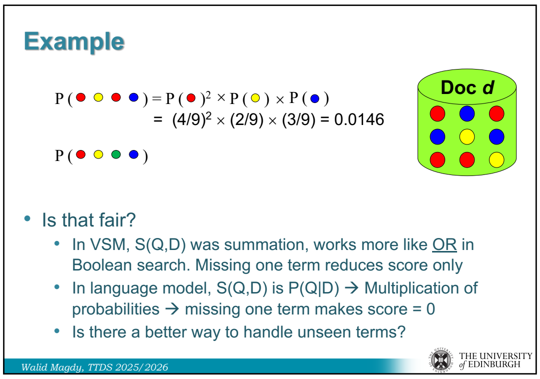

27

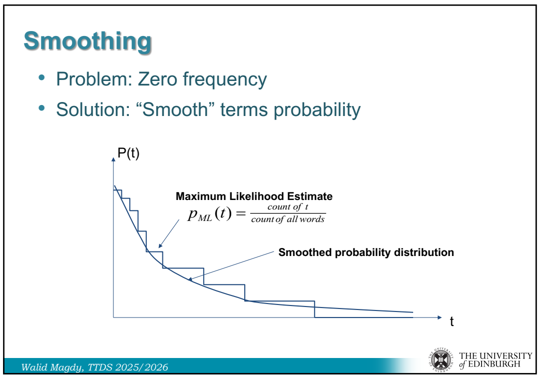

28

原 PPT 第 14 页

人话直觉

一篇文章没出现某个词，不代表它的主题模型绝不可能说这个词；样本没见到不等于世界不存在。

精确定义 / 机制： MLE 通常用 tf(t,d)/|d| 估计 document LM。若 query term 没出现在 document 中，概率为 0，整个 query likelihood 乘积变 0。这对检索过于严厉，因为 document text 只是语言模型的一个 sample。

$$P_{MLE}(t \mid M_d) = \frac{tf(t,d)}{|d|}$$

考试问法： 若问为什么需要 smoothing，答 zero frequency/data sparsity：unseen query term 会让 P(q|M_d)=0。

9. Smoothing：给没见过的词留一口气

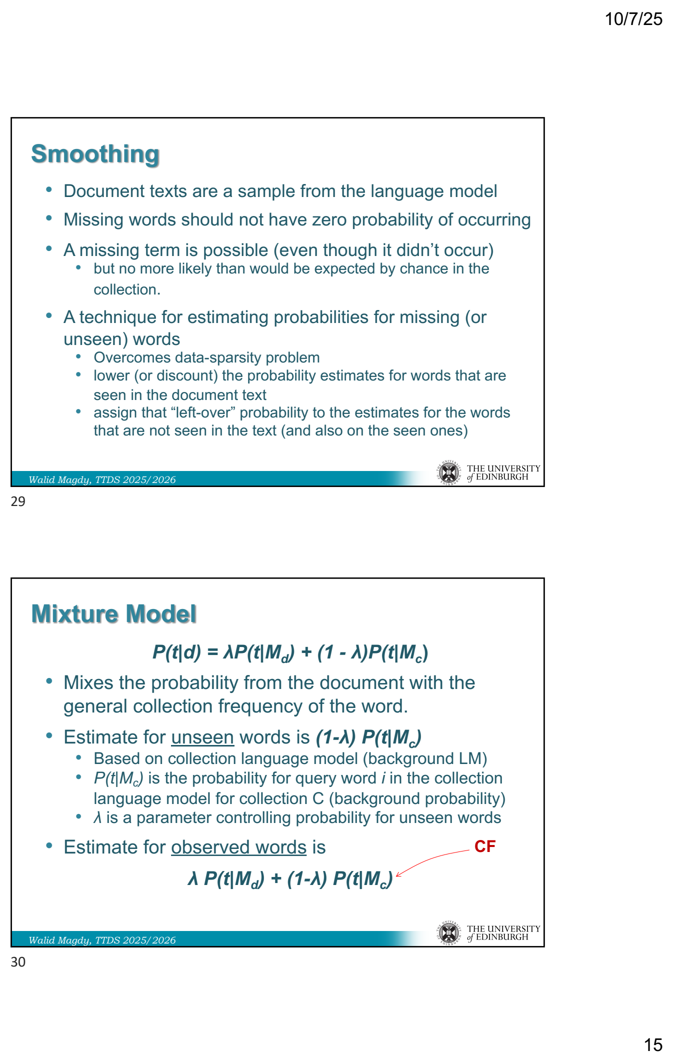

原 PPT 第 15 页

人话直觉

没在这篇文档里见过的词，不该判死刑；可以向整个 collection 借一点背景概率。

精确定义 / 机制： smoothing 给 unseen terms 分配非零概率，同时降低 observed terms 的过度自信估计。mixture/Jelinek-Mercer smoothing 将 document LM 与 collection LM 线性混合，lambda 控制文档证据和背景语言的权衡。

$$P(t \mid d) = \lambda P(t \mid M_d) + (1 - \lambda) P(t \mid M_c)$$

考试问法： 若考 smoothing，说明目标是解决 zero probability，并写 document LM 与 collection LM 的混合。

10. λ 的检索行为：conjunctive vs disjunctive

10/7/25

Jelinek-Mercer Smoothing

$P(t|d) = \lambda P(t|M_d) + (1 - \lambda)P(t|M_c)$

- **High value of λ**: “conjunctive-like” search – tends to retrieve documents containing all query words.
- **Low value of λ**: more disjunctive, suitable for long queries
- Correctly setting λ is important for good performance.
- Final Ranking function:

$$P(q|M_d) \propto \prod_{1 \le k \le |q|} (\lambda \cdot P(t_k|M_d) + (1-\lambda) \cdot P(t_k|M_c))$$

Walid Magdy, TTDS 2025/2026 THE UNIVERSITY of EDINBURGH

31

Example

- **Collection**: d_1 and d_2
- **d_1** : “Jackson was one of the most talented entertainers of all time”
- **d_2**: “Michael Jackson anointed himself King of Pop”
- **Query *q***: Michael Jackson
- Use mixture model with λ = 1/2
- $P(q|d_1)$ = [(0/11 + 1/18)/2] · [(1/11 + 2/18)/2] ≈ 0.003
- $P(q|d_2)$ = [(1/7 + 1/18)/2] · [(1/7 + 2/18)/2] ≈ 0.013
- Ranking: $d_2 > d_1$

Walid Magdy, TTDS 2025/2026 THE UNIVERSITY of EDINBURGH

32

16

原 PPT 第 16 页

人话直觉

λ 高时更执着于本文档有没有这些词，像 AND；λ 低时更宽容，像 OR 风格的长 query 检索。

精确定义 / 机制： Jelinek-Mercer 中高 lambda 更依赖 document LM，倾向检索包含所有 query words 的 documents，表现为 conjunctive-like。低 lambda 更多借 collection background，行为更 disjunctive，适合 long queries。

考试问法： lambda 行为常考：高 λ 更 conjunctive-like；低 λ 更 disjunctive/long-query friendly。

11. 三种模型问的是不同问题

10/7/25

LMs for IR: 3 possibilities

- Probability of generating the query text from a document language model
- Probability of generating the document text from a query language model
- Comparing the language models representing the query and document topics

Walid Magdy, TTDS 2025/2026 THE UNIVERSITY of EDINBURGH

35

Summary

- **Three ways to model IR**
- VSM
  How query vector aligns with document vector?
- Probabilistic Model
  What is the relevance probability of document D given query Q?
- LM
  How likely is it possible to observe/generate sequence of terms Q in a language model of document D?

Walid Magdy, TTDS 2025/2026 THE UNIVERSITY of EDINBURGH

36

18

原 PPT 第 18 页

人话直觉

VSM 问“向量像不像”，概率模型问“相关概率多大”，LM 问“这篇文档能不能生成这个 query”。

精确定义 / 机制： VSM 使用 weighting 与 similarity；probabilistic model 显式建模 relevance probability；LM for IR 则用 language model 的生成概率解释匹配。三者都可有效，BM25 和 query likelihood LM 往往效果相近，更复杂方法可能超过 BM25。

考试问法： 模型比较题要按核心问题区分：alignment、relevance probability、query generation likelihood。

考试速记版

- VSM/TF-IDF 很强但 heuristic，没有显式 relevance probability。
- PRP：按 decreasing probability of relevance 排序，估计越准越好。

- P_true(rel|Q,D) 可理解为跨未观察用户/情境的相关比例。
- BM25 = saturated TF + IDF + document length normalization。
- LM for IR：document language model 生成 query 的概率越高，排名越靠前。
- MLE 会让 unseen query term 概率为 0，因此需要 smoothing。
- Jelinek-Mercer：$\lambda P(t|M_d)+(1-\lambda)P(t|M_c)$，$\lambda$ 控制 conjunctive/disjunctive 行为。

一段稳妥考场回答

Probabilistic retrieval 的核心是把 IR 中的不确定性形式化，并按 relevance probability 排序。PRP 认为，如果能基于可用数据尽可能准确估计 $P(R=1|d,q)$，按该概率递减排序可获得最优 effectiveness。BM25 是概率检索思想中最重要的实际公式之一，它结合 saturated term frequency、IDF 和 document length normalization，因此比朴素 TF-IDF 更稳。Language Model for IR 则为每个 document 建 LM，并按 $P(q|M_d)$ 即 document model 生成 query 的概率排序；MLE 会导致 unseen terms 概率为 0，所以需要 smoothing，如 Jelinek-Mercer 用 $\lambda P(t|M_d)+(1-\lambda)P(t|M_c)$ 混合文档模型和 collection 背景模型。