

Comparing Text Corpora (2): Topic Models, LDA, and Inference

图文讲义版：用原 PPT 作为视觉锚点，按“概念故事线 + 直觉解释 + 考试速记”整理。

plate notation 表达重复随机过程 → unigram model 建立最朴素的词生成基线 → mixture of unigrams 让每篇文档先选一个主题 → pLSI 允许同一文档混合多个主题但依赖 document ID → LDA 用 Dirichlet prior 生成 document-topic mixture → model inference 从 corpus 反推 θ 、 Φ 和 latent z → Gibbs sampling 用反复重采样近似后验 → topic modelling 与 annotation/classification 形成两条 corpus analysis 路线

Background: Plate Notation

3


Björn Ross, TTDS 2025/2026



3

Background: Plate Notation

Make a basket



4

Björn Ross, TTDS 2025/2026





4

这节课一句话

这节课一句话:topic modelling 是把一堆文档想象成“主题调色盘”生成出来的过程,LDA 用 Dirichlet prior 让每篇文档能混合多个主题,再用近似推断从已观察到的词倒推出隐藏主题。

1. 1. Plate notation: 把重复过程折叠成一张图



2

人话直觉



不要把 plate notation 看成神秘数学图; 它像菜谱里的“重复 N 次”: 同一个投篮动作、同一个掷骰过程、同一个生成 word 的小机器, 被框起来批量执行。

精确定义 / 机制: plate 表示某些随机变量和依赖关系会重复出现。课件先用 basketball shooting accuracy 影响 make basket 的例子, 再把 first/second/third/nth basket 折叠成一个带 N 的 plate。之后所有 topic model 图里, N 通常表示一篇 document 内的 word tokens, M 表示 corpus 中的 documents。考

试看图时，先问：哪些变量重复？哪些变量共享？箭头表示谁影响谁？

考试问法：常见问法是解释 plate notation 中 N/M 的意义，或根据图说明变量 w 、 z 、 θ 是否按 word 或 document 重复。答题不要只说“框框”，要说它压缩表达 repeated random variables 和 conditional dependencies。

2. 2. Unigram model: 只有一个全局词袋的世界



5

原 PPT 第 5 页

人话直觉

想象全班所有文章都从同一个巨大的抽词罐里抓词：无论文章讲狗、车还是政治，都用同一套词概率。这当然粗糙，但它是理解后续模型的地板。

精确定义 / 机制：unigram model 假设每个 word 独立地从同一个 vocabulary probability distribution 生成；文档只是 words 的 sequence/vector。句子概率就是逐词相乘。课件例子中“My dog barked at another dog.”的概率按 my、dog、barked、at、another、dog 的单词概率连乘得到。它的价值是清楚展示 generative model 的基本思想；局限是完全不区分 documents 或 topics。

$$P(w_1, \dots, w_N) = \prod_{i=1}^N P(w_i)$$

考试问法：若问 unigram probability，写出 product of word probabilities；若问局限，强调 one global word distribution、independence assumption、不能表达文档主题差异。

3. 3. 为什么不能只追求“文本概率越高越好”

Probability with a Unigram Model

$$p(\mathbf{w}) = \prod_{n=1}^N p(w_n)$$

word	my	at	dog	another	barked
probability	.1	.1	.05	.04	.03

Solution:

My dog barked at another dog.

$.1 * .05 * .03 * .1 * .04 * .05 = 3e-8$

13

Björn Ross, TTDS 2025/2026
THE UNIVERSITY of EDINBURGH

Unigram Model...

- What is the point of making these models more complex?
- Why not just use the basic unigram model for everything?
- Remember:
 - Higher text probability *doesn't imply a better model*
 - We want to **accurately describe** the data
 - higher probability for *real* documents, lower probability for noise

14

Björn Ross, TTDS 2025/2026
THE UNIVERSITY of EDINBURGH

7

原 PPT 第 7 页



人话直觉

一个模型如果给所有胡言乱语也很高概率，就像老师给所有答案都满分：看似宽容，实际没判别力。

精确定义 / 机制：课件在 unigram 后追问：为什么还要更复杂模型？关键不是让所有 possible text 概率都高，而是让真实语料中的 documents 高、noise 或不符合语料结构的文本低。topic model 的复杂度来自它想解释：不同文档为什么有不同词分布，同一文档内部为什么词会围绕某些 latent themes 聚集。

考试问法：若考“more complex model 的 point”，不要答成“提高所有 probability”。应答：better fit real documents while assigning lower probability to noise，并能捕捉 document/topic structure。

4. 4. Mixture of unigrams: 每篇文档只戴一顶主题帽



16

8

原 PPT 第 8 页

人话直觉



比 unigram 进步的一步是：先决定这篇文章是 pets 还是 vehicles，然后整篇文章都从那个主题的词罐里抽词。但帽子只能戴一顶。

精确定义 / 机制： mixture of unigrams 为每个 document 采样一个 latent topic z ，然后该文档所有 words 都从 $P(w|z)$ 生成。计算文档概率时，要对所有可能 topics 做加权求和：每个 topic 的 prior $P(z)$ 乘以该 topic 下所有词概率的乘积。它能表达不同 documents 来自不同 topics，却不能表达一篇文章同时谈 pets 和 vehicles。

$$P(\mathbf{w}) = \sum_z P(z) \prod_{i=1}^N P(w_i | z)$$

考试问法： 常见比较题：相对 unigram，它有 document-level topic；相对 LDA/pLSI，它每篇 document 只有一个 topic，不能混合。计算题要记得 sum over z 。

5. 5. pLSI: 一篇文档终于可以混合多个主题



10

原 PPT 第 10 页

人话直觉



pLSI 像给每篇文章一张专属歌单：60% topic 1、40% topic 2；每生成一个词时，先按这张歌单选 topic，再按 topic 选词。

精确定义 / 机制：pLSI 的关键变量是 document ID d 。模型可理解为先选择 document，再根据 $P(z|d)$ 为每个 word 选择 topic，最后从 $P(w|z)$ 生成 word。它比 mixture of unigrams 灵活，因为同一 document 内不同 word token 可以来自不同 topics。局限也来自 d ：参数随训练 documents 增长，对 unseen documents 缺少自然 generative process。

$$P(d, w) = P(d) \sum_z P(z | d) P(w | z)$$

考试问法：若问 pLSI 与 LDA 区别，抓住 docID dependency：pLSI 学的是每个已见文档的 topic mixture；LDA 用 Dirichlet prior 生成 topic mixtures，更自然处理新文档。

6. 6. LDA: 给每篇文档先抽一盒彩色主题颜料



12

原 PPT 第 12 页

人话直觉

LDA 的文档不是单色，也不是手工登记好的歌单，而是先从 Dirichlet 分布抽出一份“主题配方” θ ：可能 70% sports、20% politics、10% tech；每个词再按这份配方选主题和选词。

精确定义 / 机制： Latent Dirichlet Allocation 是生成式 topic model。对每篇 document，从 Dirichlet prior α 采样 document-topic distribution θ ；对每个 word token，先从 θ 采样 latent topic z ，再从该 topic 的 topic-word distribution Φ 采样 observed word w 。 β 控制 topic-word distribution/prior。 θ 是 document over topics， Φ 是 topic over words， z 是每个 token 的隐藏主题 assignment， w 是看到的词。


$$\theta_d \sim \text{Dirichlet}(\alpha), \quad z_{d,i} \sim \text{Multinomial}(\theta_d), \quad w_{d,i} \sim \text{Multinomial}(\Phi_{z_{d,i}})$$

考试问法： LDA 生成过程是高频题。答题顺序必须是 document-level θ ，再 word-level z ，再 observed w ；同时说明 α/β 是 priors/smoothing，不要把 θ 和 Φ 混为一谈。

7. 7. Model inference: 从词的脚步反推隐藏主题

Model Inference

- Want to learn the model parameters
- Exact inference becomes intractable



The diagram illustrates the model inference process. A stack of papers labeled 'Corpus' is input into a black box labeled 'Topic Modeling Method'. From this box, two arrows point to the right. The top arrow points to a blue box labeled 'Document-Topic Matrix' with dimensions k (rows) and d (columns). The bottom arrow points to a yellow box labeled 'Topic-Word Matrix' with dimensions V (rows) and k (columns).

26

Björn Ross, TTDS 2025/2026

THE UNIVERSITY of EDINBURGH

Model Inference

- Instead, use an approximate method such as:
 - Gibbs sampling
 - Variational Inference

27

Björn Ross, TTDS 2025/2026

THE UNIVERSITY of EDINBURGH

13

原 PPT 第 13 页

人话直觉

真实世界里我们只看到文章里的词，看不到每个词背后是哪一个 topic。inference 就像侦探：根据词共现的脚印，倒推每个主题爱用什么词、每篇文档混了哪些主题。

精确定义 / 机制： inference 的目标是给定 corpus 学习 latent topic assignments 与参数，尤其是 document-topic matrix θ 和 topic-word matrix Φ 。课件指出 exact inference becomes intractable，因为所有 token 的 topic assignment 组合空间巨大。因此实际使用 approximate inference，例如 Gibbs sampling 或 variational inference。

考试问法： 若问为什么 exact inference 难，回答 latent assignments combinatorial explosion；若问输出，回答 θ =document-topic probabilities, Φ =topic-word probabilities。

8. 8. Gibbs sampling: 一次只重猜一个词的 topic

Gibbs Sampling for LDA

Goal: Learn Φ, θ given a set of documents D

Φ = topic-word probabilities
 θ = document-topic probabilities

Known:
corpus, α, β and the probability that a word is from a topic conditional on the assignments of all other words to topics

$$P(z_i = j | \mathbf{z}_{-i}, w_i, d_i) \propto \frac{C_{w_i j}^{-WT} + \beta}{\sum_{k=1}^K C_{w_i k}^{-WT} + W\beta} \frac{C_{d_i j}^{-DT} + \alpha}{\sum_{k=1}^K C_{d_i k}^{-DT} + T\alpha}$$

Note: the α symbol means "proportional to"

Björn Ross, TTDS 2025/2026

28

THE UNIVERSITY of EDINBURGH

Gibbs Sampling for LDA

Want to learn Φ, θ given a set of documents D

1. Assign each word a topic randomly
2. Calculate count matrices
3. Repeat until convergence:
 - For every document d
 - For every word i
 - Decrement count matrices C^{-WT} and C^{-DT} for current topic assignment
 - Sample a new topic assignment
 - Increment count matrices C^{-WT} and C^{-DT} for new topic assignment
4. Calculate Φ and θ

Björn Ross, TTDS 2025/2026

29

THE UNIVERSITY of EDINBURGH

14

原 PPT 第 14 页

人话直觉

Gibbs sampling 像给每个词贴主题便利贴：一开始乱贴，然后每次撕下一张，根据周围统计重新贴；反复很多轮后，便利贴分布逐渐稳定。



精确定义 / 机制： Gibbs sampling for LDA 在已知 corpus、 α, β 的条件下学习 Φ 和 θ 。基本步骤是：随机初始化每个 word token 的 topic；维护 topic-word counts 与 document-topic counts；对某个 token 重采样前先 decrement 它当前 assignment 的 counts；再根据其他 tokens 的 assignments 计算该 token 属于各 topic 的条件概率；采样新 topic 并 increment counts；重复直到 convergence 或固定迭代数。 α/β 起 smoothing/prior 作用，避免零概率并影响分布形状。

$$P(z_{d,i} = k | \mathbf{z}_{-d,i}, w) \propto (C_{d,k}^{-i} + \alpha_k) \frac{C_{k,w_i}^{-i} + \beta_{w_i}}{\sum_v C_{k,v}^{-i} + \sum_v \beta_v}$$

考试问法： 流程题要写出 random initialization、remove current assignment、sample new topic from conditional distribution、update counts、repeat until convergence。还要强调它是 approximate/prob-

abilistic，不保证每次同一结果。

9. 9. Topic modelling 之后：解释、例子与分类路线



23

原 PPT 第 23 页

人话直觉

topic model 给你“地图上的未知区域”；classification 则是你已经有地名和标签，训练导航系统把新文档自动归类。

精确定义 / 机制：课件后段展示 topic modelling examples，并引出 annotation + classification。传统 supervised learning workflow 是 annotate representative samples、train a classifier、apply to rest of data；transfer learning 是找一个大而相似的数据集训练，可选 fine-tune 到小数据集，再应用。classification 后还可以分析每个 class 的 relevant features、common words/topics，以及 predicted classes 与其他 variables 的关系。

考试问法：比较题常问 topic modelling vs classification：前者多为 unsupervised、发现 latent topics；后者 supervised、用预定义 labels 预测 classes。有 label 和明确分类目标时用 classification；探索语料主题时用 topic modelling。

考试速记版

- Plate notation = repeated variables/dependencies; N 常是 words, M 常是 documents。
- Unigram: 所有词来自一个全局分布, 句子概率为逐词概率连乘。
- Mixture of unigrams: 每篇文档一个 topic; document probability 要 sum over topics。
- pLSI: 每篇文档有 topic mixture, 但依赖 document ID, 不自然生成 unseen docs。
- LDA: θ 是 document-topic, Φ 是 topic-word, z 是 token-level latent topic。
- LDA generative story: $\theta \sim \text{Dir}(\alpha)$, 每词 $z \sim \theta$, $w \sim \Phi_z$ 。
- Inference 学 $\theta/\Phi/z$; exact inference intractable, 所以用 Gibbs/variational。
- Gibbs sampling: 随机初始化、移除当前计数、按条件概率重采样、更新、到收敛。
- Topic modelling 探索 hidden themes; classification 用 labels 自动打类。

一段稳妥考场回答

如果考 LDA 与前序模型的比较, 可以这样答: unigram model 假设所有词独立来自同一个全局 word distribution, 因此不能表达文档差异; mixture of unigrams 为每篇文档选择一个 latent topic, 再从该 topic 的 word distribution 生成所有词, 但一篇文档只能有一个主题; pLSI 允许每篇文档有自己的 topic mixture, word 先从 $P(z|d)$ 选 topic 再从 $P(w|z)$ 生成, 但它依赖已见 document ID, 参数随文档增加且对新文档不够自然。LDA 在 pLSI 基础上加入 Dirichlet prior: 每篇 document 先从 α 采样 θ_d , 每个 word token 再采样 $z_{d,i}$ 和 $w_{d,i}$ 。实际只观察到 words, 所以需要 approximate inference, 例如 Gibbs sampling, 通过反复重采样 topic assignments 来估计 document-topic matrix θ 和 topic-word matrix Φ 。