


Web Search (1): Massive Web Data, PageRank, Anchor Text, and Link Spam

图文讲义版：用原 PPT 作为视觉锚点，按“概念故事线 + 直觉解释 + 考试速记”整理。

web collection massive and messy → relevance ambiguity and subjective intent → massive data can improve top precision → web as directed graph → links as votes and anchor text as descriptions → PageRank models random surfer authority → anchor text enriches target representation → ranking signals invite spam and gaming → modern ranking uses PageRank as one feature among many

11/5/25



3

Challenges

- No design/co-ordination
- Growing
 - 20 PB/day in 2008 → 160 PB/day in 2013 → now??
 - 1 PB = 1,000 TB = 1,000,000 GB
- Controlling quality!
 - fake news, spam, generated content
- Challenging for a search engine
 - Technicalities: (storage, processing, ...)
 - Apparently relevant pages with low quality
- **Opportunity!**

Walid Magdy, TTDS 2025/2026

THE UNIVERSITY of EDINBURGH

4


2

这节课一句话

这节课一句话：Web search 的难点不是“有没有网页”，而是如何在巨大、混乱、可被操纵的 web graph 中，把 relevance、authority 和 anchor descriptions 变成可排序的信号。

1. 1. Web collection: 搜索引擎面对的是野生互联网

11/5/25



3

Challenges

- No design/co-ordination
- Growing
 - 20 PB/day in 2008 → 160 PB/day in 2013 → now??
 - 1 PB = 1,000 TB = 1,000,000 GB
- Controlling quality!
fake news, spam, generated content
- Challenging for a search engine
 - Technicalities: (storage, processing, ...)
 - Apparently relevant pages with low quality
- **Opportunity!**

Wahid Magdy, TTDS 2025/2026 THE UNIVERSITY of EDINBURGH

4

2

原 PPT 第 2 页

人话直觉

传统数据库像图书馆书架，web 更像全城便利贴：没人统一编号、每天疯长、还混着广告、谣言、spam 和机器生成内容。

精确定义 / 机制： Web document collection 没有 design/co-ordination，规模极大且持续增长；对 search engine 来说，挑战包括 storage、processing、networking，以及更棘手的 quality control。大量 apparently relevant pages 可能低质量，甚至故意迎合排名算法。这里的关键是：web search 同时是 IR 问题、工程问题和对抗问题。

考试问法： 若问 web search challenges，按三类答：scale/technicalities、quality control、spam/SEO

对抗；再补一句 massive data 也是 opportunity。

2. 2. Relevance ambiguity: 同一个 query 可以有很多意图

11/5/25

What is the challenge in relevance?

- No clear semantics, contrast:
 - "William Shakespeare"
 - Author history's? list of plays? a play by him?
- Inherent ambiguity of language:
 - polysemy: "Apple", "Jaguar"
- Relevance highly subjective
- On the web: counter SEOs / spam
- **Potential solution: Wisdom of the crowds**

Walid Magdy, TTDS 2025/2026

THE UNIVERSITY of EDINBURGH

5

Effect of Massive data

- Challenges: storage, processing, networking, ...
- Advantages: Makes stuff easier, how?
- Assume two good search engines the collects two sub-sets of the web
 - Search engine A collected N docs → precision@10 = 40%
 - Search engine B collected 4N docs → precision@10??

Walid Magdy, TTDS 2025/2026

THE UNIVERSITY of EDINBURGH

6

3

原 PPT 第 3 页


人话直觉

用户搜“Apple”，可能想买手机、查公司股价、找水果营养；搜“William Shakespeare”，也可能要传记、作品列表或某一部戏。query 短，意图长。


精确定义 / 机制：Web relevance 没有清晰语义，语言本身有 polysemy，且 relevance highly subjective。web 上还有 counter SEOs/spam 试图让页面看起来相关。课件提出 potential solution: wisdom of the crowds，也就是从大量用户和网页作者行为中提取信号，例如 links、anchor text、clicks 等。
考试问法：考 relevance challenge 时，不要只说“query ambiguous”；要提 no clear semantics、polysemy、subjectivity，以及 web-specific spam/SEO。

3. 3. Massive data effect: 大索引会把好结果往前推

11/5/25



7



8

4

原 PPT 第 4 页

人话直觉

如果好网页像沙子里的金粒，铲四倍沙子不保证每粒更纯，但 top 10 里更容易出现更多金粒。


精确定义 / 机制：课件比较两个好搜索引擎：A 抓 N 个 docs, precision@10=40%; B 抓 $4N$ 个 docs。在相关/非相关 score distribution 类似时，给定 score threshold 的 precision/recall 可相近，但因为 corpus 更大，top score 区域可包含更多 relevant docs，于是 $P@n$ 可能上升。这里强调 web search 中 larger index often beats a cleverer retrieval algorithm。

$$P@k = \frac{|\{\text{relevant documents in top } k\}|}{k}$$


考试问法：若问 big data vs clever algorithm, 答: 更大 index 通常增加 top-ranked relevant candidates, 改善 precision@k; 但前提是 retrieval system decent 且 score distributions roughly comparable。

4. 4. Web as directed graph: 链接既是 vote, 也是文本线索

11/5/25



11



12

6

原 PPT 第 6 页

人话直觉


网页之间的 hyperlink 像论文引用: A 链到 B, 至少说明 A 的作者认为 B 有某种价值; 链接文字 anchor 则像给 B 贴的外部标签。

精确定义 / 机制: 把 web 看成 directed graph: pages 是 nodes, hyperlinks 是 directed edges。课件给出两个 assumptions: link denotes author perceived relevance/quality signal; anchor text describes target page textual context。PageRank 利用第一点, 把 links 当 votes; anchor text 利用第二点, 把链接文字加入目标页的表示。


考试问法: 若问 PageRank/anchor text 的基础假设, 分别答 link as vote/quality signal 和 anchor as target description。注意方向: A 的 anchor text 描述的是 B, 而不是 A。

5. 5. PageRank intuition: 随机冲浪者停在哪里

11/5/25



13



14

7

原 PPT 第 7 页

人话直觉

想象一个无聊网友随机打开网页，然后不断随机点出链；偶尔厌倦了就随机跳到别处。长期看，他更常停留的页面就是更有 authority 的页面。

精确定义 / 机制： PageRank 将 page importance 定义为 random surfer 当前在 page x 的稳态概率。一个 page 的 PR 来自两部分：teleportation 的均匀基础概率，以及所有 incoming pages 按各自 outgoing links 平分后传来的 authority。高 PR 页面的一条链接，比很多低 PR 页面的链接更有分量。


考试问法： PageRank 定义题要说 random surfer steady-state probability；机制题要说 incoming links contribute $PR(y)/L_{out}(y)$ ，source 的权威越高、outlinks 越少，贡献越大。

6. 6. PageRank algorithm: teleportation 防止图里迷路

11/5/25

PageRank: Algorithm

- Initialize $PR_0(x) = \frac{100\%}{N}$
 - N : total number of pages
 - $PR_0(A) = \dots = PR_0(K) = \frac{100\%}{11} = 9.1\%$
- For every page x
$$PR_{t+1}(x) = \frac{1-\lambda}{N} + \lambda \sum_{y \rightarrow x} \frac{PR_t(y)}{L_{out}(y)}$$
 - $y \rightarrow x$ contributes part of its PR to x
 - Spread PR equally among out-links
 - Iterate till converge $\rightarrow$ PR scores should sum to 100%




Walid Magdy, TTDS 2025/2026 THE UNIVERSITY OF EDINBURGH

15

PageRank: Example

- Let $\lambda = 0.82$
- $PR_0(C) = PR_0(B) = \dots = \frac{100\%}{11} = 9.1\%$
- $PR_1(C) = \frac{(1-0.82)}{11} + 0.82 \times PR_0(B)$
$$= 0.18 \times 9.1\% + 0.82 \times 9.1\%$$
$$= 9.1\%$$
- $PR_1(B) = \frac{0.18}{11} + 0.82 \times [PR_0(C) + \frac{1}{2}PR_0(D) + \frac{1}{3}PR_0(E) + \frac{1}{2}PR_0(F) + \frac{1}{2}PR_0(G) + \frac{1}{2}PR_0(H) + \frac{1}{2}PR_0(I)]$
$$\approx 0.31 = 31\%$$
- $PR_2(C) = \frac{0.18}{11} + 0.82 \times 31\% \approx 26\%$



Walid Magdy, TTDS 2025/2026 THE UNIVERSITY OF EDINBURGH

16

8

原 PPT 第 8 页

人话直觉

如果只沿链接走，用户可能被困在小圈子或走到没有出链的死胡同；teleportation 就像“重新打开一个随机网页”的逃生按钮。

精确定义 / 机制：初始化时每个 page 可设 $PR_0(x) = 1/N$ 。每轮更新时，page x 得到 $(1-\lambda)/N$ 的随机跳转概率，再加上所有指向 x 的 pages y 传来的 $\lambda \cdot PR_i(y)/L_{out}(y)$ 。 λ 是继续沿 hyperlink 浏览的概率， $1-\lambda$ 是 random jump。迭代到收敛后，PageRank scores 总和应为 1。没有 inlinks 的页面只得到 teleportation 部分。

$$PR_{i+1}(x) = \frac{1-\lambda}{N} + \lambda \sum_{y \rightarrow x} \frac{PR_i(y)}{L_{out}(y)}$$


考试问法：公式题要解释每个符号： N total pages, λ continuation probability, $L_{out}(y)$ outgoing links count, sum over $y \rightarrow x$ 。不要忘记 teleportation term。

7. 7. Anchor text: 别人怎样称呼你，比你自我介绍更有用

11/5/25

PageRank: Example result

- Algorithm converges after few iterations



- Observations
 - Pages with no inlinks: $PR = (1 - \lambda)/N = 0.18/11 = 1.6\%$
 - Same (or symmetric) inlinks $\rightarrow$ same PR (e.g. **D** and **F**)
 - One inlink from high PR $\gg$ many from low PR (e.g. **C** vs **E**)

Wolaid Magdy, TTDS 2025/2026 THE UNIVERSITY OF EDINBURGH

17

Anchor Text

- Anchor Text (text of a link):
 - Description of destination page
 - Short, descriptive like a query
 - Re-formulated in different ways
 - Human "query expansion"
- Used when indexing page content
 - Add text of all anchor text linking the page
 - Different weights for different anchor text
 - Weighted according to PR of linking page
- Significantly improves retrieval



Wolaid Magdy, TTDS 2025/2026 THE UNIVERSITY OF EDINBURGH

18

9

原 PPT 第 9 页

人话直觉

IBM 页面自己未必反复写“Big Blue”，但很多外部网页可能用“Big Blue”链接它。anchor text 把这种群众描述收集起来，补进目标页。

精确定义 / 机制：Anchor text 是 hyperlink 中可见的链接文本，常是 target page 的 concise description。搜索引擎可把所有指向某页的 anchor texts 加入该页的 index representation，相当于 human query expansion。不同 linking pages 的 anchor text 还可按 source page 的 PageRank 或质量加权。它能显著提升 retrieval，因为它提供目标页自身可能没有的描述性词。

考试问法：若问 anchor text 为什么有用：答 external concise description、adds terms to target page index、helps match queries absent from page content；注意它也会带来 anchor text spam。

8. 8. Vulnerabilities: 排名信号一公开，就会被当成游戏规则

11/5/25

Vulnerabilities

- Hawthorne Effect: "Observation changes behavior"
- Goodhart's Law: "When a measure becomes a target, it ceases to be a good measure"
- The Cobra Effect: "The solution worsens the problem due to other incentives"




Wahid Magdy, TTDS 2025/2026

THE UNIVERSITY of EDINBURGH

19

Trackback Links Spam

- "Blogs that link to me" feature
 - Pings the linked page (Sping)
 - Artificial feedback loops
 - Similar to "follow back" on Twitter



Wahid Magdy, TTDS 2025/2026

THE UNIVERSITY of EDINBURGH

20

10

原 PPT 第 10 页

人话直觉

如果学生知道老师只按关键词数量给分，作文就会变成关键词堆砌；如果网页知道 links 能涨排名，就会制造 links。

精确定义 / 机制：课件用 Hawthorne Effect、Goodhart's Law、Cobra Effect 概括 ranking signal 的脆弱性：被观察会改变行为；measure 成为 target 后不再是好 measure；错误激励会让问题变糟。PageRank 与 anchor text 一旦影响排名，网站就会围绕它们优化甚至作弊。


考试问法：可用一句高级答法：web ranking is adversarial because signals are endogenous; once used for ranking, publishers optimize/gamify them。再接具体例子。

9. 9. Link spam: comment、trackback、link farm 的共同套路

11/5/25

Comment Spam

- Links from comments on sites with high PR
 - One solution: insert `rel=nofollow` into links
 - Link ignored when computing PR



950 thoughts on "Introduction to Computational Social Science open"

AMAZON FKRRI MUKUYET on 9/11/2023 at 14:54 said:
Your site looks very nice. You have excellent infrastructure.

Spam link in the name field

Spam link in the comment


THE UNIVERSITY of EDINBURGH

Walid Magdy, TTDS 2025/2026

21

Link Farms

- Fake densely-connected graph (a clique)
- Hundreds of web domains / IPs can be hosted on one machine



Applied on social media:
Elmas T, Randi M, Attia Y. #TeamFollowBack: Detection & analysis of follow back accounts on social media. ICWSM 2024

THE UNIVERSITY of EDINBURGH

Walid Magdy, TTDS 2025/2026

22

11

原 PPT 第 11 页

人话直觉

所有 link spam 都在做同一件事：伪造“别人推荐我”的社会证明，让搜索引擎误以为目标页受欢迎。

精确定义 / 机制：Trackback link spam 利用 blogs that link to me 等机制制造 artificial feedback loops; comment spam 在高 PR 网站评论区放 spam links，解决方式之一是 `rel=nofollow`，使 link 不参与 PR 计算；link farms 则由大量 fake densely-connected pages/domains 组成 clique，人工制造链接权威。Anchor text spam 则通过大量特定 anchor text 操纵某 query 排名。

考试问法：若考 vulnerability，至少举两个例子并说明它们操纵的是 link signal 或 anchor text signal；再说明 nofollow、spam detection 和多特征 ranking 是应对方向。

10. 10. Reality: PageRank 很重要，但不是现代排名的全部

11/5/25

Summary

- Web data is massive
 - Challenging for efficiency, but useful for effectiveness
- PageRank:
 - Probability than random surfer is currently on page x
 - The more powerful pages linking to x, the higher the PR
- Anchor text:
 - Short concise description of target page content
 - Very useful for retrieval
- Link Spam
 - Trackable links, link farms

Walid Magdy, TTDS 2025/2026



27

Resources

- Text book 1: Intro to IR, Section 21.1
- Text Book 2: IR in Practice: 4.5, 10.3
- Page Rank Paper:
Page, L., Brin, S., Motwani, R., & Winograd, T. (1999).
The PageRank citation ranking: Bringing order to the web.
Stanford InfoLab.
- Additional reading:
 - Dumais, S., Banko, M., Brill, E., Lin, J., & Ng, A. (2002).
Web question answering: Is more always better?.
SIGIR 2002.
 - Elmas T, Randl M, Attia Y.
#TeamFollowBack: Detection & analysis of follow back accounts on social media.
ICWSM 2024

Walid Magdy, TTDS 2025/2026



28

14

原 PPT 第 14 页

人话直觉

PageRank 是搜索史上的发动机，不是今天整辆车。现代搜索还要刹车、导航、传感器和反作弊系统。

精确定义 / 机制：课件总结 PageRank 曾是重大突破，核心价值是利用 collective linking behavior 估计 page authority；但现在它只是众多 ranking features 之一。现代 web ranking 还会使用 content features、user behaviour、spam signals、machine-learned ranking、Learning to Rank 等。

考试问法：若问 PageRank 是否仍是 Google ranking 全部，明确答 no；说明它是 authority/link feature，现代系统会结合多种 features 与 ML ranking。

考试速记版

- Web challenges: scale、quality、spam/SEO、storage/processing/networking。
- Relevance 难: query ambiguous、polysemy、subjective、web spam。

- Massive data can improve P@k because more relevant candidates appear near top. 主
- Web graph: page=node, link=edge; link as vote, anchor as target description。
- PageRank = random surfer steady-state probability。
- 公式核心: teleportation + incoming PR divided by source outdegree。
- Anchor text = human query expansion for target page indexing。
- Goodhart: ranking measure 成为 target 后会被 gaming。
- Spam examples: traceback spam、comment spam、link farms、anchor text spam。
- Modern ranking: PageRank is one feature, not the whole story.

一段稳妥考场回答

如果考 PageRank, 可以这样答: PageRank 把 web 建模为 directed graph, 把 page 的 importance 定义为 random surfer 长期停留在该 page 的概率。初始化可令每个 page 的 PR 为 $1/N$; 每次迭代中, page x 获得 teleportation 部分 $(1-\lambda)/N$, 并从所有指向 x 的 pages y 获得 $\lambda \cdot PR(y)/L_{out}(y)$ 的贡献。 λ 表示继续沿 hyperlink 浏览的概率, $L_{out}(y)$ 是 y 的 outgoing links 数量。因此, 来自 high-PageRank page 的 inlink 比来自很多 low-PageRank pages 的 links 更有价值。PageRank 利用群众链接行为估计 authority, 但 link/anchor signals 会被 comment spam、traceback spam、link farms 等操纵, 所以现代 ranking 只把 PageRank 作为众多 features 之一。